

Salym — простое объяснение: что это такое и какую задачу решает

Зачем этот документ

Этот файл написан специально простым языком. Без технического жаргона. Его цель — ответить на три вопроса:

1. Что такое Salym и зачем он у нас появился?
2. Что лежит в этой "сводной таблице" и почему она выглядит сложно?
3. Какую задачу Salym решает ЛУЧШЕ всего — и почему это не то же самое, что мы делали раньше?

Если коротко — **это другой датасет для другой задачи**, не просто "больше тех же данных". И ниже подробно, почему.

1. Что мы делали раньше (контекст)

Чтобы понять, что не так с Salym, надо вспомнить, что у нас уже есть.

Текущая система ALMA работает так:

- У нас **5-8 скважин** для каждого типа аномалии.
- Три типа аномалий: негерметичность НКТ, изменение притока, солеотложение.
- Для каждой скважины **заказчик заранее сказал**: "вот здесь, в такое-то время, была аномалия".
- Мы берём период ДО аномалии — это **норма**, модель её запоминает.
- Мы берём период ПОСЛЕ — это **стрим**, модель его анализирует и пытается найти отклонение.
- Метрика успеха: **насколько рано модель обнаружила аномалию** относительно её реального начала.

Главное здесь — **у нас была готовая разметка**. Кто-то пришёл и сказал: "вот тут сломалось с такого-то числа". Это как учитель, который отмечает правильные ответы в тетради.

2. Что такое Salym и откуда он взялся

Salym — это новое, большое месторождение, с которого нам дали **два источника данных**:

2.1. Телеметрия (parquet-файлы)

- Папка `salym/parquet/`
- **120 файлов, 67 гигабайт**
- 30 параметров датчиков × 4 года (2015–2018)
- Это сырые показания датчиков со скважин: давление, температура, токи, вибрации

Из 30 параметров Salym мы берём 15, которые совпадают с нашим текущим датасетом:

Вибрация X, Вибрация Y, Вибрация Z, Выходная частота, Давление на приёме насоса, Дисбаланс токов, Коэффициент загрузки ПЭД, Линейное напряжение АВ, Линейное напряжение ВС, Линейное напряжение СА, Температура на приёме насоса, Ток на фазе А, Ток на фазе В, Ток на фазе С, Температура масла двигателя.

Оставшиеся 15 параметров Salym (CasingHeadPressure, ChokeSize, ESP.RunStatus, FluidLevel, Residuals.Lab, Sediments.Lab и другие) мы пропускаем — их нет в текущих данных, и включать их — значит ломать совместимость.

Из 26 параметров нашего текущего датасета **мы теряем 11**, их в Salym нет: фазное напряжение Ua, Ub, Uc; Cos Ф; активная выходная мощность; полная выходная мощность; напряжение постоянного тока ПЧ; вибрация XY; вибрация XYZ; дисбаланс напряжений; выходной ток ПЧ.

2.2. Сводная таблица (Excel)

- Файл `salym/сводная_информация_салим.xlsx`
- Один лист — `ESP Database`
- **5 801 строка, 291 колонка**
- В шапке написано: "RUN LIFE REPORT. Version 2.0"

Вот с этой таблицей и связана вся путаница. Давайте разберёмся, что в ней.

3. Что такое "сводная таблица" простыми словами

3.1. Главная мысль одной фразой

Сводная таблица — это НЕ данные с датчиков. Это журнал ремонтов и отказов оборудования.

Если провести аналогию с автомобилем:

- **Parquet-файлы** — это бортовой компьютер машины. Он каждую секунду пишет: скорость, обороты двигателя, температура, расход топлива.
- **Сводная таблица** — это сервисная книжка машины. В ней написано: "04.05.2015 — плановое ТО, заменили масло", "12.09.2015 — сломался стартер, заменили", "20.01.2016 — не завёлся в мороз, разобрали, нашли севший аккумулятор".

Это **два принципиально разных источника**:

- Parquet = "как вела себя машина каждую секунду"
- Excel = "что с машиной случилось в жизни и что ремонтировали"

3.2. Что означает одна строка в Excel

Одна строка = **один эпизод жизни одной установки на одной скважине.**

Представьте: на скважине стоит насос. Его установили в мае 2005. Он работал 2 года. Потом сломался в сентябре 2007. Его сняли, поставили новый. Новый проработал 3 года. И так далее.

Каждая такая история "установили — работал — сломался — сняли" = одна строка Excel.

Поэтому у одной скважины в Excel может быть **много строк**:

- У среднестатистической скважины — 4 строки (4 раза меняли оборудование).

- Максимум — 21 строка (очень "многострадальная" скважина).
- Минимум — 1 строка (одна установка за всё время).

Все три примера ниже — **из окна 2015-2018 года**, то есть из того периода, за который у нас есть телеметрия в раquet. Набор колонок во всех таблицах одинаковый.

Перевод колонок, которые встречаются в примерах

Английское название	Перевод	Что значит
Installed	Установлен	Дата, когда установку физически спустили в скважину
Started	Запущен	Дата фактического запуска в работу (обычно через 1-3 дня после Installed). Если пусто — оборудование не дожидло до первого запуска
Failed	Отказал	Дата фиксации отказа или окончания цикла
Runtime	Наработка, дней	Сколько фактически проработало (дробные значения — часы/минуты)
Reason	Причина работ	Бизнес-классификация: зачем вообще проводились работы (Ремонт / Освоение / Оптимизация)
Kind workover	Тип ремонта	Что конкретно делали (Смена УЭЦН, ГРП, Освоение после бурения, и т.д.)
stop_reason	Причина остановки	Техническое событие: почему оборудование перестало работать (R=0, Клин, ГТМ, и т.д.)
Failed Equipment	Отказавшее оборудование	Конкретный узел, который вышел из строя (Seal section, Pump section1, Cable MLE1, и т.д.)

Реальный пример 1 — скважина WS-1333 (6 циклов за 2015-2016)

Installed	Started	Failed	Runtime	Reason	Kind workover	stop_reason	Failed Equipment
2015-03-06	2015-03-07	2015-05-24	79.2	Ремонт	ГРП, Смена ЭЦН	R=0	Seal section
2015-05-28	2015-05-30	2015-06-01	3.7	Ремонт	Смена УЭЦН	Клин	Pump section1
2015-06-10	2015-06-11	2016-02-10	245.2	Ремонт	Смена ЭЦН	Клин	Seal section
2016-02-15	2016-02-18	2016-06-05	110.9	Ремонт	смена УЭЦН	R=0	Seal section
2016-06-11	2016-06-16	2016-11-22	164.4	Ремонт	Смена УЭЦН	R=0	Motor-top
2016-12-11	2016-12-14	2016-12-14	3.1	Ремонт	смена УЭЦН	Отсутствие подачи насоса	—

Читается так: за 2015-2016 на скважине сменили **6 комплектов** оборудования. Один цикл пережил 245 дней, другие — от 3 до 164 дней. Три раза отказала **гидрозащита** (Seal

section — секция уплотнения, которая защищает мотор от пластовой жидкости), один раз — **верхняя секция мотора** (Motor-top). Такие скважины — кандидаты на тяжёлую деградацию, вероятнее всего с агрессивной средой (высокое давление пластовой воды, которое пробивает уплотнения).

Временная шкала циклов WS-1333 (визуализация)



Что видно на диаграмме:

- **Два цикла почти мгновенные** (2-4 дня, красные) — оборудование не прижилось, заклинило сразу или сразу после смены.
- **Три цикла средней длины** (80-165 дней) — "нормальные" отказы на пробеге.
- **Один длинный цикл** — 245 дней, почти 8 месяцев.
- **Пробелы между циклами** (несколько дней) — это операция: вытащить старое, спустить новое.

Реальный пример 2 — скважина WS-5638 (6 циклов за 2015-2016)

Installed	Started	Failed	Runtime	Reason	Kind workover	stop_reason	Failed Equipment
2015-04-24	2015-04-26	2015-07-15	81.5	Ремонт	Смена УЭЦН	ГТМ	—
2015-08-28	2015-08-30	2015-09-01	4.4	Оптимизация	Подготовка и освоение после ГРП	Клин	Pump section1
2015-09-23	2015-09-25	2015-09-26	3.0	Ремонт	Смена УЭЦН	Клин	Pump section1
2015-12-16	2015-12-19	2016-02-08	53.7	Ремонт	Смена УЭЦН	Не герметичность лифта	Pump section1
2016-03-07	2016-03-09	2016-03-10	2.3	Ремонт	смена УЭЦН	R=0 при спуске	Pump section1
2016-08-28	2016-08-30	2016-08-30	2.3	Ремонт	—	Клин	Pump section1

Читается так: в 5 из 6 циклов отказала именно первая секция насоса (Pump section1) — устойчивый паттерн. Причины остановки разные: Клин, Не герметичность лифта, R=0 при спуске — но узел тот же. Это означает, что **среда скважины агрессивна к насосу** (возможно, песок, абразив, соли). Такие паттерны — ключевой материал для задачи предсказания отказа по типу узла.

Реальный пример 3 — скважина US-129 (6 циклов за 2015-2017, включая NaN)

Installed	Started	Failed	Runtime	Reason	Kind workover	stop_reason	Failed Equipment
2015-03-10	2015-03-12	2015-09-22	195.8	Ремонт	Смена УЭЦН	ГТМ	—
2015-11-13	2015-11-15	2015-12-09	26.6	Ремонт	ГТМ, ГРП, смена УЭЦН	ГТМ	—
2016-01-19	— (не запустился)	2016-01-20	0.6	—	—	R=0 при спуске	Cable MLE1
2016-01-21	2016-01-23	2016-07-17	178.4	Ремонт	Смена УЭЦН, WSO	R=0	Seal section
2016-07-29	— (не запустился)	2016-07-30	0.25	Ремонт	Смена УЭЦН	R=0 при спуске	—
2016-07-30	2016-08-01	2017-02-05	189.5	Ремонт	Смена УЭЦН	R=0	Single motor

Читается так: 2 цикла из 6 завершились ещё до первого запуска (Started = NaN, Runtime < 1 дня) — это отказ на спуске. Два цикла — ГТМ (плановое вмешательство). В двух отказавших есть конкретный узел: кабель (Cable MLE1) и односекционный мотор (Single motor). Этот пример показывает два важных типа записей — **NaN в Started** (цикл не дожид до запуска) и **NaN в Failed Equipment** (не известно, что именно отказало).

В чём разница между Reason и stop_reason

Эти два поля путают. Они про **разные вещи**:

Поле	Что это	Примеры значений	Кто "автор" значения
Reason	Зачем проводились работы (бизнес-причина вмешательства)	Ремонт / Освоение / Оптимизация / —	Решение инженера/оператора
stop_reason	Почему оборудование перестало работать (техническая причина)	R=0 / Клин / ГТМ / Не герметичность лифта / Отсутствие подачи / Полёт УЭЦН / ...	Событие с железкой

Иллюстрация на WS-1333, цикл 4:

- Reason = Ремонт — оператор принял решение "будем делать ремонтные работы на скважине".
- stop_reason = R=0 — физическая причина, почему к нему пришли: на пульте сработала защита по потере сопротивления изоляции.

Иллюстрация на WS-5638, цикл 2:

- Reason = Оптимизация — работы проводились **не по поломке**, а чтобы перевести скважину на другой режим после гидроразрыва пласта.
- stop_reason = Клин — но во время этих работ всё равно случился заклини насоса.

Ключевая асимметрия:

- Reason может быть Оптимизация — это означает, что **оборудование не отказывало**, его меняли ради производительности. В таких случаях stop_reason часто пустое или содержит технологическое событие (например, ГРП).
- Reason = Освоение — это **ввод скважины в работу после бурения или сложной операции**, тоже не поломка.
- Reason = Ремонт — чаще всего идёт в паре с реальной stop_reason (R=0, Клин, Отсутствие подачи и т.д.).

Для задачи анализа отказов Reason = Ремонт — это **нужные нам кейсы**. Reason = Оптимизация и Reason = Освоение — это "шум", от которого надо отфильтровываться, потому что там **оборудование не ломалось**.

Точные числа из Excel (5 801 строка):

Reason	Сколько
Ремонт	3 626
— (пусто)	891
Освоение	845
Оптимизация	439

Как соотносятся Reason , stop_reason и Failed Equipment

У одного цикла могут быть заполнены **все три поля одновременно**, и каждое описывает свой аспект события. Это не дубли, а три разных "угла зрения":

Уровень	Поле	Что описывает	Пример (WS-1333, цикл 1)
1. Бизнес	Reason	Зачем пришли к скважине	Ремонт — проводим ремонтные работы
2. Симптом	stop_reason	Что сработало на пульте / что видно инженеру	R=0 — сработала защита по потере изоляции
3. Диагноз	Failed Equipment	Какая железка реально вышла из строя (выяснилось при разборе)	Seal section — при разборе нашли, что пробило гидрозащиту

Полная цепочка причин в примере WS-1333 (цикл 1):

- Износилась гидрозащита (Failed Equipment = Seal section)
- пластовая жидкость проникла к мотору
- обмотка мотора отсырела, пробой изоляции
- на пульте сработала защита, сопротивление упало (stop_reason = R=0)
- оператор завёл работы (Reason = Ремонт , Kind workover = ГРП, Смена ЭЦН)
- разобрали установку, подтвердили диагноз (Failed Equipment = Seal section)

Почему важно различать:

- stop_reason — это то, что **видно в реальном времени**. Это "симптом", как температура у больного.

- **Failed Equipment** — это то, что **выясняется после разборки**. Это "диагноз", как заключение врача.

Один и тот же симптом может давать разные диагнозы:

- **R=0** → может быть: **Seal section** (295 раз), **Cable MLE1** (104), **Single motor** (87), **Pump section1** (59), **Motor-top** (46) и т.д.

Один и тот же узел может давать разные симптомы:

- **Pump section1** → может быть: **Отсутствие подачи** (137), **Клин** (101), **R=0** (59), **Снижение подачи**, **Не герметичность лифта** и т.д.

Для задачи предсказания отказа ценнее Failed Equipment — он говорит, что физически ломается. Но он заполнен только в 36% случаев (1 362 из 3 797 циклов), поэтому на практике приходится работать со связкой (**stop_reason + Failed Equipment**) и принимать решения с учётом пропусков.

3.3. Почему 291 колонка — и что в них

Колонок много, потому что это большой журнал. Вот что в нём лежит, сгруппированное по смыслу — с реальными значениями из таблицы:

Блок "Идентификация" (колонки 0-3)

Поля: **Field**, **Pad**, **Well**, **Unique Job identifier**.

Примеры реальных значений:

- **Field** = "Upper Salym", **Pad** = "K01", **Well** = "US-103", **Unique Job identifier** = "US-103-WOV003"
- **Field** = "West Salym", **Pad** = "K56", **Well** = "WS-1403", **Unique Job identifier** = "WS-1403-WOV012"

Зачем это нам: именно по этим полям мы связываем строку Excel с телеметрией. **pad = K01 + well = US-103** → **WellPad01/Well103** в parquet.

Блок "Даты цикла" (колонки 33-41)

Поля: **Installed**, **Started trial**, **Started**, **No. Starts**, **Failed**, **Pulled**, **Teardown**, **Runlife**, **Runtime**.

Примеры:

- **Installed** = 2003-05-06, **Started** = 2003-05-08, **Failed** = 2005-09-10, **Pulled** = 2005-09-16, **Runtime** = 858 дней.

Смысл каждого поля:

- **Installed** — когда установку спустили в скважину (6 мая 2003).
- **Started trial / Started** — пробный пуск и фактический рабочий пуск. Разница обычно 1-2 дня.
- **Failed** — когда зафиксирован отказ или окончание цикла.
- **Pulled** — когда физически подняли наверх (обычно через несколько дней после Failed).
- **Teardown** — когда разобрали для расследования.
- **Runtime** — сколько фактически проработала (дни, дробные — часы/минуты считаются).
- **Runlife** — elapsed time "от первого запуска до отказа", в Excel почти везде стоит 500.

Блок "Причина работ" (колонки 11-32)

Поле Reason — всего 3 значения на все 5 801 строку:

- **Ремонт** — 3 626 строк. Что-то сломалось, заменили.
- **Освоение** — 845 строк. Скважина вводится в работу после бурения или сложных операций.
- **Оптимизация** — 439 строк. Замена оборудования **без поломки**, для повышения производительности (пример из WS-1403 выше: "Оптимизация, смена Э-79 на Э-199").
- Пустое (NaN) — 891 строка.

Поле Kind workover (тип работ, топ-10 из 78 уникальных значений):

Значение	Строк
Смена УЭЦН	1 318
смена УЭЦН (та же причина, другой регистр)	1 109
Пустое	709
Освоение после бурения	523
Смена ЭЦН	224
освоение	127
ГРП, смена УЭЦН	90
освоение гориз. скважины	58
Смена УЭЦН, ГРП	44
Смена УЭЦВН	43

Расшифровки:

- **УЭЦН** — установка электроцентробежного насоса (полный комплект).
- **ЭЦН** — сам электроцентробежный насос (без дополнительных секций).
- **УЭЦВН** — установка электроцентробежного насоса высокооборотного.
- **ГРП** — гидроразрыв пласта (крупная технологическая операция по увеличению притока нефти).

Блок "Причина остановки" (колонки 43-62)

Главное поле — The reason of a stop . Детально разобрано в разделе 3.4 ниже.

Плюс бинарные колонки-флаги (да/нет) для основных типов: R=0 , Shaft of the pump (вал насоса), Not tightness of pipes (негерметичность труб), Absence of submission of the pump (отсутствие подачи), Flight of the pump (полёт насоса), Decrease in submission of the pump (снижение подачи).

Блок "Что именно отказало" (колонка 62: Failed Equipment)

Самое полезное поле для классификации отказа по узлу. Разобрано в разделе 3.4.

Блок "Post-mortem" (колонки 63-94)

Поля Мероприятие\Action 1..5 — что делали после отказа (например: "разборка", "промывка", "замена фильтра"). Плюс Result of analysis of the pump, Result of analysis of the motor, Result of analysis of the seal, Result of analysis of the gas separator, Result of analysis of the cable.

Это уже выводы инженеров **постфактум**. Полезно для понимания, что нашли при разборе. Для онлайн-детектора бесполезно.

Блок "Лабораторные анализы" (колонки 95-133)

Поля Sampling point, Sampling data, Visual environment, Microscope observation results, Water and water soluble components, Interaction with 15 % HCl, Calcium carbonate, Solids deposits, Adjournment of salt, Adjournment paraffine, Processing by chemical reagents.

Здесь фиксируется химический анализ среды: был ли карбонат кальция, парафин, соли, как реагирует на кислоту. **Это самый близкий блок к нашей теме солеотложения** — но только если лаборатория действительно пробы брала (заполненность этих полей низкая).

Блок "Паспорт оборудования" (колонки 134+)

Разделы: Motor/ПЭД, Pump/Насос, Protector/Гидрозащита, Gas Separator/Газосепаратор, Pump compressor pipes/НКТ, Кабельная линия, Термостойкая вставка, The transformer, Control station.

Это характеристики конкретных железок, которые стояли в этом цикле: модель мотора, серийник, мощность, длина кабеля, тип трансформатора. Полезно для анализа надёжности по моделям оборудования.

Заполненность очень разная: Motor/ПЭД заполнен хорошо, Pump/Насос хуже, блок НКТ заполнен крайне слабо.

Почему так много "Unnamed" колонок

Примерно 150 из 291 — это колонки с именем вида Unnamed: 7, Unnamed: 115. Это не отдельные поля, а **подколонки внутри больших merged-заголовков Excel**. Пример: в шапке одна объединённая ячейка "Мероприятие\Action 1", а под ней три подколонки (дата, исполнитель, описание). При чтении pandas видит только первую с именем, остальные становятся "Unnamed". Осмысленного содержания в самом имени нет — надо смотреть, что за родительский заголовок выше.

3.4. Что в реальности лежит в самых важных полях

Причины остановки (stop_reason)

Из **3 797 циклов оборудования** (файл equipment_cycles.parquet) причина остановки указана в **3 256** случаях (541 цикл — без указания, примерно 14% пропусков).

Полное распределение всех реальных значений:

Причина	Сколько циклов	Что это значит
---------	----------------	----------------

R=0	1 592	Потеря сопротивления изоляции (R = resistance). Физически — электрика "пробила", чаще всего короткое замыкание в обмотке мотора или повреждение кабеля
ГТМ	651	Геолого-технические мероприятия — плановое вмешательство (например, кислотная обработка, изменение режима). НЕ поломка оборудования
— (не указано)	541	В Excel поле пустое
Отсутствие подачи насоса	445	Насос вращается, но нефть на устье не поступает (засор на приёме, срыв подачи, пескопроявление)
Клин	223	Механическое заклинивание — насос или мотор физически не крутится
R=0 при спуске	122	Электрика отказала ещё на этапе спуска установки в скважину (до первого запуска)
Не герметичность лифта	109	Утечка в колонне НКТ — нефть не поднимается вверх, потому что вытекает через пробойну
Прочее	74	Редкие причины, не вошедшие в основные категории
Снижение подачи насоса	38	Постепенная деградация производительности (насос качает, но меньше нормы)
Полёт УЭЦН	2	Авария — установка оборвалась и упала на забой скважины

Какое оборудование отказало (failed_equipment)

Заполнено в **1 362 циклах из 3 797** (36%, а не 31% — уточнил). В 2 435 циклах поле пустое. Это значит: **для двух третей поломок Salym не говорит, какой именно узел вышел из строя.**

Полный список всех 33 значений с точными цифрами:

Узел	Сколько	Что это за железка
Seal section	339	Гидрозащита (секция уплотнения). Защищает мотор от попадания пластовой жидкости. Работает как "сальник" между мотором и насосом
Pump section1	324	Первая секция насоса (насос обычно многосекционный, считается сверху или снизу — зависит от производителя)
Cable MLE1	120	Кабель MLE1 — силовой кабель первого типа (круглого сечения)
Cable standard1	109	Кабель стандартный, первая секция
Single motor	98	Односекционный мотор — погружной электродвигатель простой конструкции (не составной)
Cable standard2	56	Кабель стандартный, вторая секция
Motor-top	49	Верхняя секция мотора (в составных/многосекционных моторах)
Cable standard3	42	Кабель стандартный, третья секция
Pump section2	36	Вторая секция насоса

Cable high temperature1	36	Термостойкий кабель , первая секция (для скважин с высокой температурой)
Gas separator – dispenser	32	Газосепаратор-диспергатор . Отделяет газ от жидкости перед насосом, чтобы насос не "газовал"
Motor-bottom	24	Нижняя секция мотора (в составных моторах)
Cable high temperature2	16	Термостойкий кабель, вторая секция
Cable standard4	15	Кабель стандартный, четвёртая секция
Pump section3	11	Третья секция насоса
Down hole sensor system	9	Глубинная система датчиков (TMC — телеметрическая система)
Cable MLE	8	Кабель MLE без номера секции
Pump section4	7	Четвёртая секция насоса
Cable high temperature3	6	Термостойкий кабель, третья секция
Cable standard	4	Кабель стандартный без номера
Drain valve	3	Сливной клапан
Cable high temperature	3	Термостойкий кабель без номера
Cable standard5	3	Кабель стандартный, пятая секция
Cable high temperature4	2	Термостойкий кабель, четвёртая секция
Motor-middle1	2	Средняя секция мотора
Pump section9	1	Девятая секция насоса
Check valve1	1	Обратный клапан (предотвращает обратный ток жидкости при остановке)
Motor-bottom1	1	Нижняя секция мотора (с номером)
Y-tool	1	Y-переходник (байпас для спуска приборов в скважину)
Pump section6	1	Шестая секция насоса
Pump section5	1	Пятая секция насоса
Additional Equipment	1	Дополнительное оборудование без уточнения
Pump section	1	Секция насоса без номера

Группировка отказавших узлов (свёрнуто по типу)

Чтобы было понятнее, сколько всего отказов по типу оборудования:

Группа	Всего отказов	Доля от 1 362 с заполненным полем
--------	---------------	-----------------------------------

Кабель (все типы + секции)	420	31%
Насос (Pump section 1-9 + без номера)	382	28%
Гидрозащита (Seal section)	339	25%
Мотор (Single + top + bottom + middle)	174	13%
Газосепаратор	32	2.4%
Датчики + клапаны + прочее	15	1.1%

То есть: **три лидера — кабель (31%), насос (28%), гидрозащита (25%)**. На них приходится 84% всех задокументированных отказов.

Как связаны причина остановки и отказавший узел

Чтобы было понятно, что отказавший узел и причина остановки — это **две разные характеристики одного события**, вот реальная кросс-таблица топ-15 пар:

Причина остановки	Что отказало	Случаев
R=0	Seal section (гидрозащита)	295
Отсутствие подачи насоса	Pump section1	137
R=0	Cable MLE1	104
Клин	Pump section1	101
R=0	Cable standard1	96
R=0	Single motor	87
R=0	Pump section1	59
R=0	Cable standard2	53
R=0	Motor-top	46
R=0	Cable standard3	37
R=0	Cable high temperature1	25
Отсутствие подачи насоса	Seal section	23
R=0	Motor-bottom	22
R=0 при спуске	Cable MLE1	16
R=0	Cable standard4	15

Как это читается:

- **R=0** (электрический отказ) в 295 случаях оказался в итоге поломкой **гидрозащиты** — это парадоксально только на первый взгляд. Физика такая: гидрозащита не выдержала → пластовая жидкость попала в мотор → изоляция обмотки пробилась → сработала защита по изоляции → на пульте видно **R=0**. То есть R=0 — это **симптом**, а реальная причина — износ гидрозащиты.
- **Клин** (механика) в 101 случае оказался поломкой насосной секции — тоже логично: заклинило именно насос, а не мотор.

- Отсутствие подачи в 137 случаях — проблема в насосной секции (износ, песок, засор).

Важный вывод: `stop_reason` описывает как оборудование перестало работать, а `failed_equipment` — какой узел реально вышел из строя. Для задачи предсказания отказа ценнее `failed_equipment`, но он заполнен только в 36% случаев.

4. Что у нас получилось после предобработки

Мы не стали работать с этим сложным Excel напрямую. Мы его разобрали на аккуратные таблицы в папке `salym_prepared/`:

4.1. Что мы отфильтровали

Из 1 248 скважин, которые упомянуты в Excel, мы взяли только те, у которых:

1. Есть полная телеметрия за все 4 года (2015–2018) — это гарантирует, что данные не обрывались.
2. Нет неоднозначности с идентификатором (иногда один номер в базе соответствует двум разным скважинам в Excel — такие 8 штук выкинули).

В итоге осталось 572 скважины. Из них **568 — "идеальные"**: полное покрытие по всем 15 нужным нам параметрам за все 4 года.

4.2. Что мы сохранили

Файл	Что в нём	Зачем
<code>metadata/selected_wells.parquet</code>	Список 572 отобранных скважин	Наш рабочий пул
<code>anomalies/equipment_cycles.parquet</code>	3 797 циклов оборудования (из Excel)	Когда что устанавливали, когда ломалось
<code>anomalies/anomaly_periods.parquet</code>	3 275 событий отказа	Точки <code>Failed</code> — но это точки, а не интервалы
<code>qc/well_parameter_coverage.parquet</code>	8 580 строк (572 скв × 15 параметров)	Сколько валидных данных по каждой паре
<code>raw_wells/<скважина>/<параметр>.parquet</code>	8 580 файлов телеметрии	Сами сырые измерения

Итог: мы имеем 568 хороших скважин × 15 параметров × 4 года телеметрии + журнал отказов для каждой. Это **большая, чистая, структурированная выборка**.

4.3. Один важный нюанс про телеметрию Salym

У разных параметров внутри одной скважины — **разная частота опроса датчиков**. Давление меряется раз в ~12 минут, частота ЭЦН тоже редко, а вибрации могут быть чаще. И эта частота **разная даже у разных скважин** для одного и того же параметра. Это не бардак, это природа промыслового учёта. Но значит, что **единой временной сетки нет** — её ещё надо будет построить отдельным шагом (ресемплинг). Пока мы сознательно оставили как есть.

5. Главное: чем Salym отличается от текущих данных

Вот пять ключевых различий. Прочитать их — значит понять, почему "просто использовать raano_shared как раньше" не работает.

5.1. В Salym нет ответа "где аномалия"

Это самое главное.

В текущей задаче заказчик сказал: "на скважине 172г аномалия началась 2025-05-03 в 11:30". Мы знаем точку старта → мы можем:

- учиться на периоде ДО этой точки;
- проверять модель на периоде ПОСЛЕ;
- измерять задержку детектора.

В Salym максимум, что есть в Excel: "установка отказала 05.03.2015 в 11:40". Но это **когда отказ уже ЗАФИКСИРОВАН**, то есть когда стало очевидно, что всё сломалось. А когда началась деградация в сигналах — **никто не знает**. Она могла начаться за неделю, за месяц, или прямо в тот же день.

Аналогия: представьте, что вас попросили предсказать, когда человек заболеет. В текущей задаче вам заранее говорят: "вот с этого дня он будет болеть, проверь, видно ли это в анализах". В Salym вам дают только запись: "человек умер 5 марта". И всё. А когда началось недомогание? Это надо искать самим.

5.2. Типы отказов в Salym не совпадают с нашими тремя классами

Наши три класса: негерметичность НКТ, изменение притока, солеотложение.

А в Salym в графе "причина остановки":

Salym stop_reason	Ближайший наш класс
Не герметичность лифта	≈ негерметичность (близко)
Отсутствие подачи / Снижение подачи	≈ приток (похоже)
R=0 (электрика)	нет аналога
Клин (механика)	нет аналога
ГТМ (плановое)	это вообще не поломка
Солеотложение	отдельно не выделено! Соли уходят в лабораторные блоки (колонки про осадки, кальций, парафин)

Примерно 55% всех циклов в Salym — это события, которые наша текущая система вообще не обучена ловить (R=0, Клин, ГТМ). И наоборот — **соли, наш основной класс, в Salym почти не отмечены как причина остановки**.

5.3. Параметров меньше — 15 из 26

В текущей системе используется 26 каналов датчиков. В Salym есть только 15 из них. Чего **нет**:

- Фазное напряжение Ua, Ub, Uc (есть только линейные AB, BC, CA)

- $\cos \Phi$ (коэффициент мощности)
- Активная и полная выходная мощность
- Напряжение постоянного тока ПЧ
- Вибрация XY и XYZ (есть только X, Y, Z отдельно)
- Дисбаланс напряжений
- Выходной ток ПЧ

Это важно: для наших лучших результатов (например, соли) топовый канал — "Коэффициент загрузки ПЭД" (есть в Salym) и "Фазное напряжение U_c " (**нет в Salym**). То есть **текущую обученную модель просто взять и запустить на Salym не получится** — половина её "любимых" каналов отсутствует. Придётся переобучать на меньшем наборе.

5.4. На одной скважине — много циклов оборудования

В текущих данных на скважине обычно один состав оборудования. В Salym среднестатистическая скважина за 4 года переживает **4 смены оборудования**, а некоторые — до 21.

Почему это важно: нельзя брать "норму" из начала 2015 года и считать отклонения в 2017 году, если между этими датами насос меняли трижды. **Это уже физически другой насос.** Его нормальное поведение другое.

Это значит: обучать и мониторить надо **внутри одного цикла оборудования**, а не "по скважине целиком". Это меняет структуру пайплайна.

5.5. Данные не приведены к единой временной сетке

В текущей системе мы работаем с аккуратной сеткой: точка каждые 2 минуты (негерметичность), 10 минут (приток), 15 минут (соли). Все каналы синхронизированы.

В Salym такого нет. У каждого параметра своя частота. Отдельным шагом надо будет всё это приводить к общей сетке, интерполировать пропуски, решать, что делать с дырами в записи.

6. Какую задачу Salym решает лучше всего

Теперь главное. Если Salym такой неудобный для текущего подхода — зачем он нам?

Ответ: Salym идеально подходит для ДРУГОЙ задачи — предсказания отказа (Failure Prediction / Remaining Useful Life).

6.1. Что это за задача

В нашей текущей задаче мы спрашиваем:

▮ "Показывают ли датчики, что прямо сейчас что-то не так?"

В задаче предсказания отказа мы спрашиваем:

▮ "Показывают ли датчики, что через N дней оборудование сломается?"

Это **фундаментально другая постановка**. Там не ищут "отклонение от нормы", там напрямую учатся на истории: "вот как ведут себя датчики за 30 дней до отказа — запомни этот паттерн".

6.2. Почему Salym для этого идеален

1. **Огромная выборка.** 568 скважин × 4 года × 4 цикла в среднем = ~2 000+ **реальных историй "работа → отказ → ремонт"**. Против наших текущих 16 размеченных аномалий — это в 125 раз больше материала.
2. **Каждая история заканчивается точкой отказа** с датой и причиной. Это **готовый таргет** для обучения.
3. **Классификация отказа по типу.** В каждой истории записано, что именно сломалось: электрика, мотор, насосная секция, кабель. Можно учиться **не просто "сломается", а "сломается из-за X"**.
4. **Разные условия.** 568 разных скважин = 568 разных "характеров" оборудования. Модель, обученная на такой выборке, обобщается гораздо лучше.
5. **Длинная история.** 4 года непрерывной телеметрии — достаточно, чтобы увидеть и сезонные паттерны, и деградационные тренды, и периоды стабильной работы.

6.3. Что в итоге можно предсказывать

- **Сколько дней осталось до отказа** (Remaining Useful Life, RUL).
- **Вероятность отказа в ближайшие 7/30/90 дней.**
- **Тип предстоящего отказа** (электрика или механика — разные предвестники).
- **Рейтинг риска по всему парку скважин** (какие установки следить пристальнее).

Это не то же самое, что "нашли аномалию в реальном времени". Это **прогноз на будущее** — принципиально более ценный инженерный инструмент.

7. Можно ли на Salym сделать "старую" задачу — коротко, да/нет

Можно ли напрямую применить текущий raano_shared?

Нет, по двум причинам:

1. У модели 26 входных каналов, в Salym только 15.
2. У модели разметка "норма/аномалия" по времени — в Salym её нет.

Можно ли адаптировать подход?

Частично. Три варианта:

Вариант А — "сделать вид, что есть разметка" Взять точку `Failed` из Excel и считать, что аномалия началась за N дней до неё (например, за 14). Тренировать модель на периоде в начале цикла, проверять на окне перед `Failed`.

Минус: это **не честная разметка**. Если модель сработает за 5 дней до `Failed` — мы не знаем, это "она молодец, поймала раньше" или "это ложное срабатывание, а реальная деградация началась всего за 2 дня". Без настоящего onset метрика задержки нечестная.

Вариант Б — валидация обобщаемости Переобучить raano_shared на 15 общих каналах на наших текущих размеченных данных, а потом прогнать на 572 Salym-скважинах как просто scoring. Проверить: **срабатывают ли алерты рядом с событиями `Failed`?**

Плюс: честная проверка "а работает ли наш подход вообще за пределами маленькой выборки". *Минус:* не даёт новой ценности, просто тест.

Вариант В — сменить задачу на Failure Prediction Это отдельный большой проект. Другой пайплайн, другие модели (скорее всего, supervised learning или survival analysis), другие метрики.

Плюс: именно под это Salym и создан. Именно это он решает по-настоящему хорошо. *Минус:* это не "расширение текущей системы", это новый продукт.

8. Рекомендация

Мой совет — делать всё это **в два шага**.

Шаг 1 (быстрый, 1-2 недели): Вариант Б

- Переобучить raano_shared на 15 каналах на текущих размеченных данных.
- Прогнать на 572 скважинах Salym.
- Проверить корреляцию алертов с событиями `Failed` из Excel.
- Получить ответ: **"обобщается ли наш подход?"**

Это минимальные усилия + честная валидация. Без переизобретения пайплайна.

Шаг 2 (большой проект, 2-3 месяца): Вариант В

- Построить отдельный Failure Prediction pipeline.
- Использовать Salym по прямому назначению.
- Новая модель, новые метрики, новый продукт.
- Это та задача, под которую Salym идеально подходит.

Чего точно НЕ стоит делать: пытаться натянуть Вариант А как основной. Без настоящей разметки onset метрики будут нечестные, а результаты — не воспроизводимые. Это путь в никуда.

9. Итог одним абзацем

Salym — это **не БОльшая версия текущего датасета**, это **другой тип данных для другой задачи**. У него нет разметки аномалий в сигнале, зато есть 568 скважин × 4 года телеметрии + подробный журнал из 2000+ реальных отказов. Это идеальный материал для **предсказания отказов** (какое оборудование скоро сломается и почему), но **не** для текущей задачи "найди отклонение от нормы в реальном времени". Чтобы использовать Salym по прямому назначению, нужно запускать **отдельный проект по Failure Prediction**, а не расширять текущую систему. А текущую систему на Salym можно **только провалидировать** — проверить, срабатывают ли алерты рядом с известными отказами из Excel.